

# Algorytmy Metaheurystyczne

## Komiwojażer Genetycznie

Gabriel Budziński(254609)  
Franciszek Stepek (256310)

## Przedmowa

Na samym początku omówimy po krótku naszą implementację, oraz podamy kilka informacji ogólnych. Następnie bardziej szczegółowo opiszemy poszczególne parametry algorytmu, a na koniec przedstawimy wyniki i opis wykonywanych eksperymentów.

## 1 Informacje ogólne

### 1.1 Implementacja

Algorytmy implementujemy w języku C/C++, odległości między wierzchołkami są przechowywane jako pełne tablice dwuwymiarowe typu `int`, a trasy (pojedyncze osobniki) są w kontenerach `vector`, co ułatwia operacje odwracania i mieszania. Korzystaliśmy z kompilatora `g++` wraz z użyciem flag `-ISDL2` (używanej przy wizualizacji, wraz z odpowiednim dla danego systemu operacyjnego podlinkowaniem do folderu zawierającego) oraz `-lpthread` (przy korzystaniu z wielowątkowości).

Dodajmy jeszcze tylko, że jako generatora pseudolosowego użyliśmy typu `std::mt19937` zdefiniowanego przez C++.

### 1.2 Sprzęt

Programy były testowane na dwóch maszynach, laptopie *Lenovo* i komputerze stacjonarnym. Obie jednostki są wyposażone w procesor architektury `x86` marki `intel` oraz 16GB pamięci RAM.

- PC - Komputer stacjonarny posiada procesor sześciordzeniowy i5-10600K 4,1 GHz (o obniżonym napięciu operacyjnym).
- Laptop - Laptop posiada procesor czterordzeniowy i7-6700HQ 2,6 GHz

### 1.3 Instancje

Używaliśmy instancji przygotowanych przez TSPLIB, które dzielą się na 2 kategorie:

- 8 instancji symetrycznych:
  - berlin52.tsp
  - st70.tsp
  - eil76.tsp
  - bier127.tsp
  - kroA150.tsp
  - lin318.tsp
  - linhp318.tsp
  - pr439.tsp
- 8 instancji asymetrycznych:
  - ftv55.atsp
  - ftv64.atsp

- ftv70.atsp
- kro124p.atsp
- ftv170.atsp
- rbg323.atsp
- rbg358.atsp
- rbg443.atsp

W dalszych częściach, instancje będziemy oznaczać przez liczbę mówiącą o rozmiarze problemu (czyli np. st70.tsp oznaczmy jako  $n = 70$ , albo po prostu 70) z drobną różnicą - aby rozróżnić lin318 od linhp318, instancję linhp318 będziemy oznaczać liczbą 319.

## 1.4 Metodologia/cel

Testy przeprowadzono za pomocą zaimplementowanych w tym celu funkcji ku jak największej automatyzacji. Dane o przeprowadzonych testach zapisywano do plików tekstowych w formacie CSV, a następnie poddane analizie. Testy i eksperymenty miały na celu zbadanie wydajności naszej implementacji, oraz znalezienie jak najlepszych trybów/hiperparametrów dla przypadku ogólnego.

## 2 Opis parametrów

W opisie przejdziemy najpierw przez kolejne 'tryby' działania, a następnie omówimy także każdy hiperparametr występujący w naszej implementacji.

Ale zanim, to wspomnijmy jeszcze tylko, że każda operacja krzyżowania daje nam 2 nowe osobniki, a przez 'Sim.' na wykresach mamy na myśli wariant symetryczny, a przez 'Asim.' - asymetryczny.

### 2.1 Tryby działania

- StartMode - sposób generowania populacji początkowej:
  - 0 - Każdy osobnik jest wybierany z 10 całkowicie losowych (Chodzi o losowe permutacje dróg)
  - 1 - Każdy osobnik jest tworzony jako puszczenie algorytmu NearestNeighbor (czyli zachłanne szukanie najbliższego sąsiada z tych co pozostali w każdej iteracji) z losowego punktu startowego
  - 2 - Hybrydowe połączenie 2 poprzednich, gdzie stosunek losowych do NN wynosi 4:1 (Czyli około 20% populacji to osobniki 'względnie dobre').
- SelectionMode - sposób w jaki jest wykonywana selekcja osobników:
  - 0 - Turniejowa, czyli wyieramy najlepszych, a najgorszych odrzucamy
  - 1 - Kwadratowo ruletkowa - najlepszy osobnik przechodzi dalej, a wszystkim pozostałym przyporządkowywane są wagi względem kwadratu pozycji (Czyli jeżeli mamy populację wielkości 15, to najlepszy przechodzi dalej, kolejny ma wagę  $14 * 14$ , później  $13 * 13$  itd., a ostatni ma wagę 1), a następnie zgodnie z nimi jest robione losowanie.
- MutMode - sposób przeprowadzenia mutacji (o jej hiperparametrach będzie później):
  - 0 - Mutacja typu *Invert*
  - 1 - Mutacja typu *Insert*
  - 2 - Mutacja typu *Swap*
  - 3 - W każdej iteracji (co to oznacza będzie powiedziane później) losowe wybranie spośród 3 poprzednich
- crossMode - używany operator do krzyżowania osobników:
  - 0 - *Order Based Crossover*
  - 1 - *Modified Order Based Crossover*
  - 2 - *Partially Mapped Crossover*

- `crossType` - sposób przeprowadzenia i selekcji osobników do krzyżowania:
  - 0 - Wszystkie osobniki są ustawione losowo, a następnie krzyżujemy ze sobą 1 z 2, 3 z 4.. itd. Jeżeli osobników było nieparzyste, to ostatni osobnik jest dublowany.
  - 1 - W każdej iteracji losowana jest para osobników z całej populacji (Ustalona liczba na sztywno, w testach = 20)
  - 2 - Tak jak poprzednio, ale tym razem liczba losowań jest określona jako rozmiar problemu / 2 (czyli dla  $n = 150$  mamy 75 losowań.
  -

## 2.2 Hiperparametry

- `time` - czas działania algorytmu - w naszych eksperymentach każde 1 wywołanie trwa 30 sekund
- `populationSize` - rozmiar populacji początkowej (oraz co za tym idzie - rozmiar w każdej iteracji, ponieważ selekcja redukuje rozmiar do rozmiaru początkowego)
- `mutationThreshold` - określa z jakim prawdopodobieństwem zachodzi mutacja (mutacja może zajść podczas tworzenia nowych osobników, rozpatrywana dla każdego z osobna)
- `mutationIntensification` - górne ograniczenie na liczbę pojedynczych mutacji na jednym osobniku (jeżeli zajdzie mutacja, to następnie jest losowana jej intensyfikacja, co najmniej 1, definiuje liczbę iteracji przy mutacji - dlatego przy zastosowaniu `MutMode3` może się okazać, że np. wykonają się 3 typu *Invert* oraz 1 typu *Swap*)
- `crossSize` - wielkość fragmentu podlegająca krzyżowaniu - przy naszych operatorach jest to wielkość 'wycinka', który definiuje operację krzyżowania
- `crossCount` - wykorzystywane tylko, gdy `crossType` 1, definiuje liczbę zachodzących krzyżowań
- `swapSize` - liczba osobników zabierana z każdej z wysp w warianccie wyspowym
- `swapInterval` - liczba iteracji pomiędzy mieszaniem osobników pobranych z wysp

### 3 Opis eksperymentów

Jako wyniki eksperymentów będziemy pokazywali wartość funkcji celu dla podanych wykonań (Zazwyczaj jako minimum, oraz średnią z 4 wywołań), w formie stosunku wartości względem najlepszej znalezionej (informacja ze strony TSPLIB). Dodatkowo czasami będziemy mówili również o liczbie wykonanych iteracji, aby zastanowić się później nad (ewentualnym) jej wpływem na ostateczny wynik.

#### 3.1 Poszukiwanie I - Tryb

Na samym początku przeprowadzony został eksperyment, który miał na celu znalezienie jak najlepszego zestawu trybów dla naszego algorytmu. Użyliśmy tutaj następującego zestawu hiperparametrów (wybranych empirycznie po kilkunastu przetestowaniach algorytmu):

- `populationSize = 20`
- `mutationThreshold = 0.05`
- `mutationIntensification = 5`
- `crossSize = 7`
- `crossCount = 20`

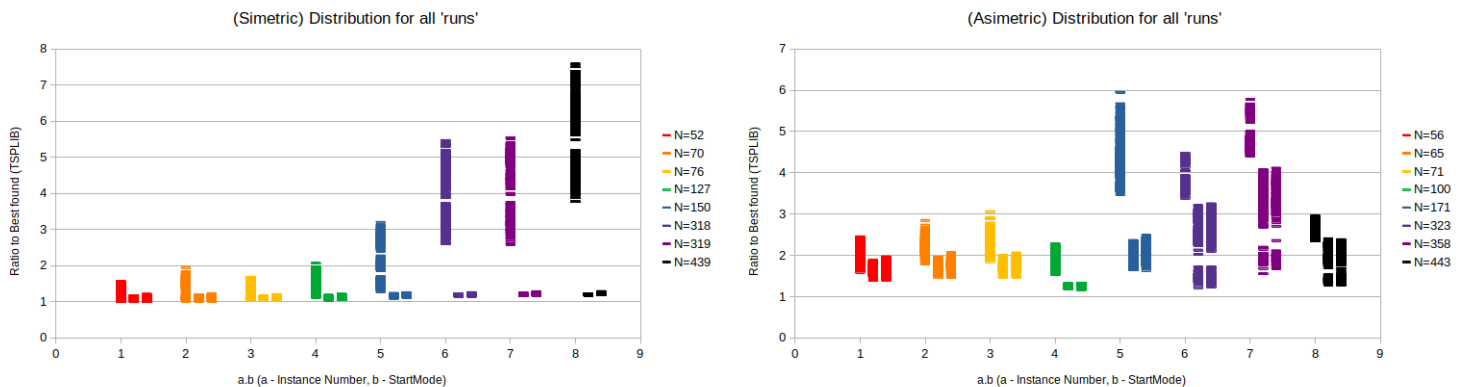
Testy wykonaliśmy dla każdej możliwej kombinacji trybów ( $3 \cdot 3 \cdot 2 \cdot 4 \cdot 3 = 216$ ), dla każdej z 16 badanych instancji. Przypomnijmy, że czas działania ograniczyliśmy do 30 sekund, a żeby odrobinę zredukować losowy wkład metody, każde wywołanie powtórzyliśmy 4 razy. Pokazanie wszystkich wyników w tabeli byłoby dosyć kłopotliwe i nieczytelne, więc ograniczymy się do kilku mniejszych tabel oraz paru wykresów.

##### 3.1.1 Ogólny rozrzut wyników

Na początek przedstawimy wykresy pokazujące rozrzut danych dla testów. Na osi Y wartością jest stosunek  $\frac{a}{b}$ , gdzie:

- $a$  - wartość funkcji celu dla pojedynczego eksperymentu
- $b$  - najlepsze znalezione rozwiązanie (wg. TSPLIB)

Dodatkowo na wykresie zawarta jest też informacja o trybie startującym, dlatego też dla instancji 'a' dane na osi X są na 3 'poziomach': a.0, a.1, a.2, gdzie kolejno oznacza to StartMode.

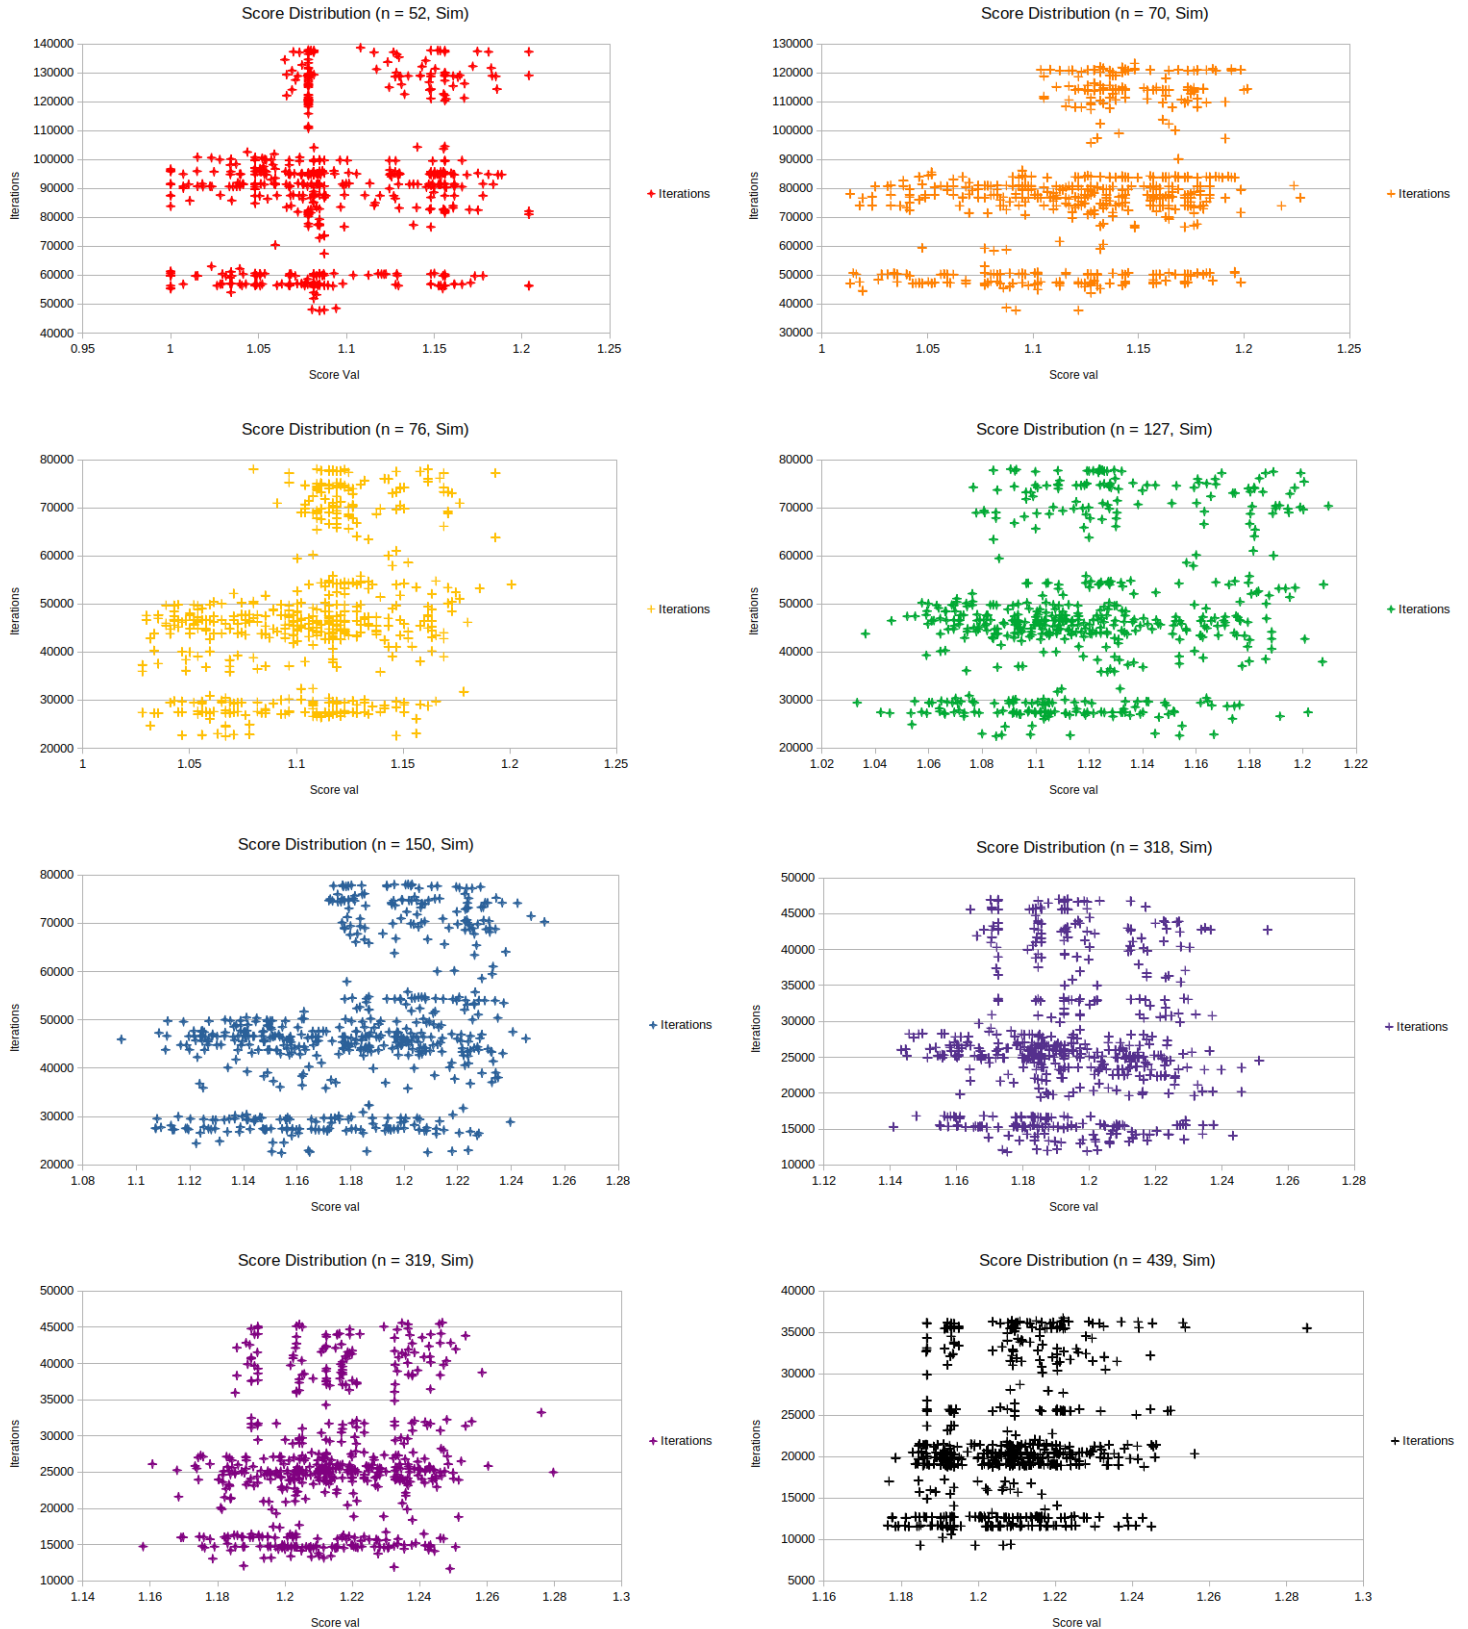










Z podanych wykresów można wyciągnąć dwa zasadnicze wnioski (które aplikują się zarówno do instancji symetrycznych, jak i asymetrycznych):

- Jak widać, dla większych instancji algorytm startujący z rozwiązań losowych nie miał wystarczającej ilości czasu, aby dotrzeć do rozwiązań (w sensie wydajności) zbliżonych do pozostałych trybów startowania. Jednak dla instancji mniejszego rozmiaru, z samego tylko wykresu trudno byłoby powiedzieć, czy jego rozwiązania są rzeczywiście gorsze, chociaż jasno widać, że mają one (o losowym starcie) znacznie większy rozrzut.
- Dla większych instancji, pomimo dużego rozrzutu danych, dla samych rozwiązań startujących z całkowicie losowej populacji można wyznaczyć dwie 'grupy', dlatego też zaryzykujemy tu stwierdzenie, że dla pozostałych trybów startu także to zachodzi (choć na razie tego nie widać)

### 3.1.2 Rozrzut wyników dla poszczególnych instancji

Pokażemy teraz dystrybucję wyniku względem liczby iteracji osobno dla każdej instancji. Jednak, nie zawrzemy tutaj wyników, które zostały otrzymane przez użycie całkowicie losowej populacji początkowej, ponieważ tak jak zauważyliśmy na poprzednich wykresach, odbiegają znacznie od pozostałych 2 trybów startujących.





Z tych wykresów wyciągniemy jeszcze kilka wniosków:

- Najbardziej rzuca się w oczy dosyć wyraźna 'klasteryzacja' rozwiązań ( najbardziej w przypadku większych instancji) - co idealnie pokazuje, że konkretne kombinacje trybów bardzo różnie ze sobą działają ( i można dzięki temu wyznaczyć prosperujące)
- Pomimo znacznej różnicy w liczbie wykonanych iteracji, nie ma bezpośredniego związku między wynikiem - oznacza to, że są tryby, które bardzo 'szybko' znajdują rozwiązanie 'dobre', pomimo tego, że wykonanie pojedynczego kroku trwa o wiele dłużej.
- W miarę zwiększania się problemu instancji widać coraz wyraźniejsze różnice między poszczególnymi kombinacjami (nie są nazwane, ale bardziej chodzi tutaj o zaakcentowanie występowania zjawiska)
- Widać również różnice dla wariantu symetrycznego, oraz asymetrycznego - drugie są o wiele bardziej 'skondensowane' mi układają się bardziej 'pasmowo' - może to wynikać z natury problemu - albo dane ruchy są wymagające, albo nie (W przypadku symetrycznych różnice są bardziej - niespodziewane - symetryczne)

### 3.1.3 Tryby pod względem jednostkowym

Pokażemy teraz tabele podsumowującą wszystkie instancje symetryczne, oraz asymetryczne, w której to zawrzemy informacje o minimum i średniej rozwiązań w rozbiciu o każdy tryb (to znaczy, że będziemy patrzeć na całą naszą przestrzeń rozwiązań, a następnie będziemy ją dzielić na rozwiązania względem danego trybu, zatem najpierw (w pierwszych 3 wierszach) podzielimy całość na 3 metody startowe, następnie całość podzielimy na 2 metody selekcji, itd.), z czego wyciągniemy informacje, jakie wartości danych trybów są ogółem najlepsze gdy się nie bierze pod uwagę kombinacji innych.

Tabela 1. Tryb	Wartość trybu	Min (Sym)	Avg (Sym)	Min (Asym)	Avg (Asym)
StartMode	0	1	2.751	1.533	2.988
	1	1	1.144	1.175	1.981
	2	1	1.165	1.164	2.008
SelectionMode	0	1	1.682	1.174	2.321
	1	1	1.691	1.164	2.331
MutMode	0	1.020	1.562	1.164	2.275
	1	1	1.736	1.179	2.338
	2	1.067	1.851	1.174	2.336
	3	1	1.597	1.175	2.330
crossMode	0	1.065	1.819	1.174	2.419
	1	1	1.616	1.180	2.277
	2	1	1.625	1.164	2.281
crossType	0	1	1.697	1.178	2.326
	1	1	1.671	1.164	2.324
	2	1	1.692	1.174	2.328

Z obu powyższych tabel możemy wyciągnąć następujące wnioski:

- Możemy zaobserwować, że zaskakująco wiele kombinacji (ponieważ każdy tryb jednostkowo wchodzi w kilkadziesiąt innych) znalazło chociaż raz rozwiązanie optymalne! Jednak jak się przyjrzymy wcześniejszym wykresom, to zauważymy, że taka sytuacja wydarzyła się jedynie dla najmniejszej z rozpatrywanych instancji.
- Dalej widać, że pod względem średniej globalnej, dane tryby z osobna nie różnią się znacznie od siebie, dlatego też o wiele więcej informacji będziemy w stanie wyciągnąć z dalszej analizy.

### 3.1.4 10 najlepszych kombinacji

Teraz spójrzmy jeszcze na ranking 10 najlepszych zestawów parametrów zebranych ze wszystkich instancji. Ranking stworzony został w następujący sposób:

- W obrębie każdej instancji:
  - Najpierw policzyliśmy minimum oraz średnią z 4 wywołań każdej kombinacji
  - Później zsumowaliśmy ze sobą obie otrzymane wartości
  - Następnie posortowaliśmy kombinacje rosnąco względem otrzymanej sumy

- Teraz przyporządkowaliśmy miejsca do otrzymanego porządku (przy dublowaniu któregoś z miejsc omijaliśmy kolejne: 32, 32, 34)
- W obrębie typu instancji (symetryczne / asymetryczne), a później globalnie (wszystkie 16 razem)
  - Zsumowaliśmy zajęte miejsca dla każdej kombinacji
  - posortowaliśmy rosnąco otrzymując ostateczny 'ranking' dla wszystkich kombinacji w obrębie danego typu.

Oto 'główki' dla otrzymanych wyników (Ostatecznie wybraliśmy pierwszy rekord z każdej):

Tabela 2. Sym.		StartMode	SelectionMode	MutMode	CrossMode	CrossType	Sum	Avg
Id								
107		1	0	3	2	2	98	12.25
102		1	0	3	1	0	124	15.5
106		1	0	3	2	1	127	15.875
103		1	0	3	1	1	141	17.625
142		1	1	3	2	1	161	20.125
139		1	1	3	1	1	163	20.375
140		1	1	3	1	2	188	23.5
143		1	1	3	2	2	197	24.625
138		1	1	3	1	0	202	25.25
104		1	0	3	1	2	206	25.75

Tabela 3. Asym.		StartMode	SelectionMode	MutMode	CrossMode	CrossType	Sum	Avg
Id								
77		1	0	0	1	2	193	24.125
75		1	0	0	1	0	225	28.125
149		2	0	0	1	2	227	28.375
76		1	0	0	1	1	250	31.25
115		1	1	0	2	1	267	33.375
114		1	1	0	2	0	270	33.75
112		1	1	0	1	1	274	34.25
185		2	1	0	1	2	276	34.5
80		1	0	0	2	2	278	34.75
113		1	1	0	1	2	289	36.125

Tabela 4. Wspólne		StartMode	SelectionMode	MutMode	CrossMode	CrossType	Sum	Avg
Id								
76		1	0	0	1	1	461	28.8125
75		1	0	0	1	0	471	29.4375
77		1	0	0	1	2	494	30.875
115		1	1	0	2	1	494	30.875
113		1	1	0	1	2	522	32.625
112		1	1	0	1	1	536	33.5
114		1	1	0	2	0	546	34.125
103		1	0	3	1	1	579	36.1875
116		1	1	0	2	2	590	36.875
111		1	1	0	1	0	596	37.25

Na koniec jeszcze taka uwaga: zaniechaliśmy zamieszczanie testów statystycznych, ponieważ każdy z badanych trybów był jednoznacznie 'dobry', albo bez znaczenia (jak na przykład StartMode = 1). Na koniec dodamy jeszcze tabelkę z pierwszymi 50 wynikami naszego rankingu, aby to podkreślić.



## 3.2 Poszukiwanie II - hiperparametry

Po wyznaczeniu rokujących zestawów trybów, przeszliśmy do wyznaczenia jak najlepszych hiperparametrów. W tym celu wyznaczyliśmy 1 zestaw dla wariantu symetrycznego (Spec), 1 dla asymetrycznego (Spec), oraz 1 wspólny (Gen).

Poprzez metodę losowego próbkowania dla każdego hiperparametru (losowy z zakresu podanego zaraz), wykonaliśmy 100 kombinacji, gdzie każdą testowaliśmy 4 razy.

Badane instancje:

- st70.tsp - sym.
- pr439.tsp - sym.
- ftv70.atsp - asym.
- rbg443.atsp - asym.

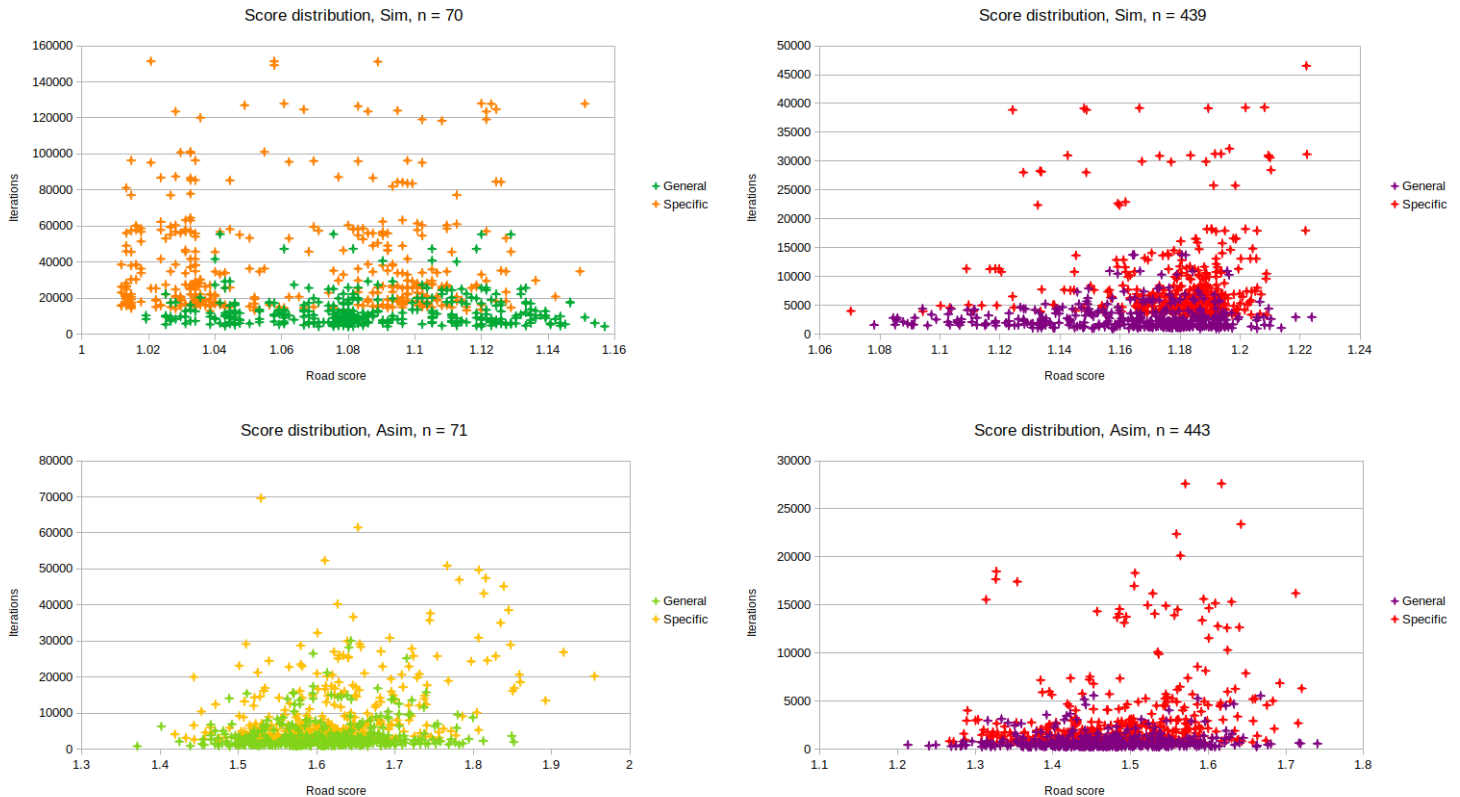
Badany zakres hiperparametrów:

- populationSize : [10; 100]
- mutationThreshold : [0.0; 1.0]
- mutationIntensification : [1; 20]
- crossSize : [2; 20]
- crossCount : [10; 200]

Z przeprowadzonych eksperymentów otrzymaliśmy następujące wyniki:

### 3.2.1 Rozrzut wyników dla poszczególnych instancji

Na samym początku zaprezentujemy na wykresach, jak wygląda rozkład otrzymanych wyników dla każdej z badanych instancji.



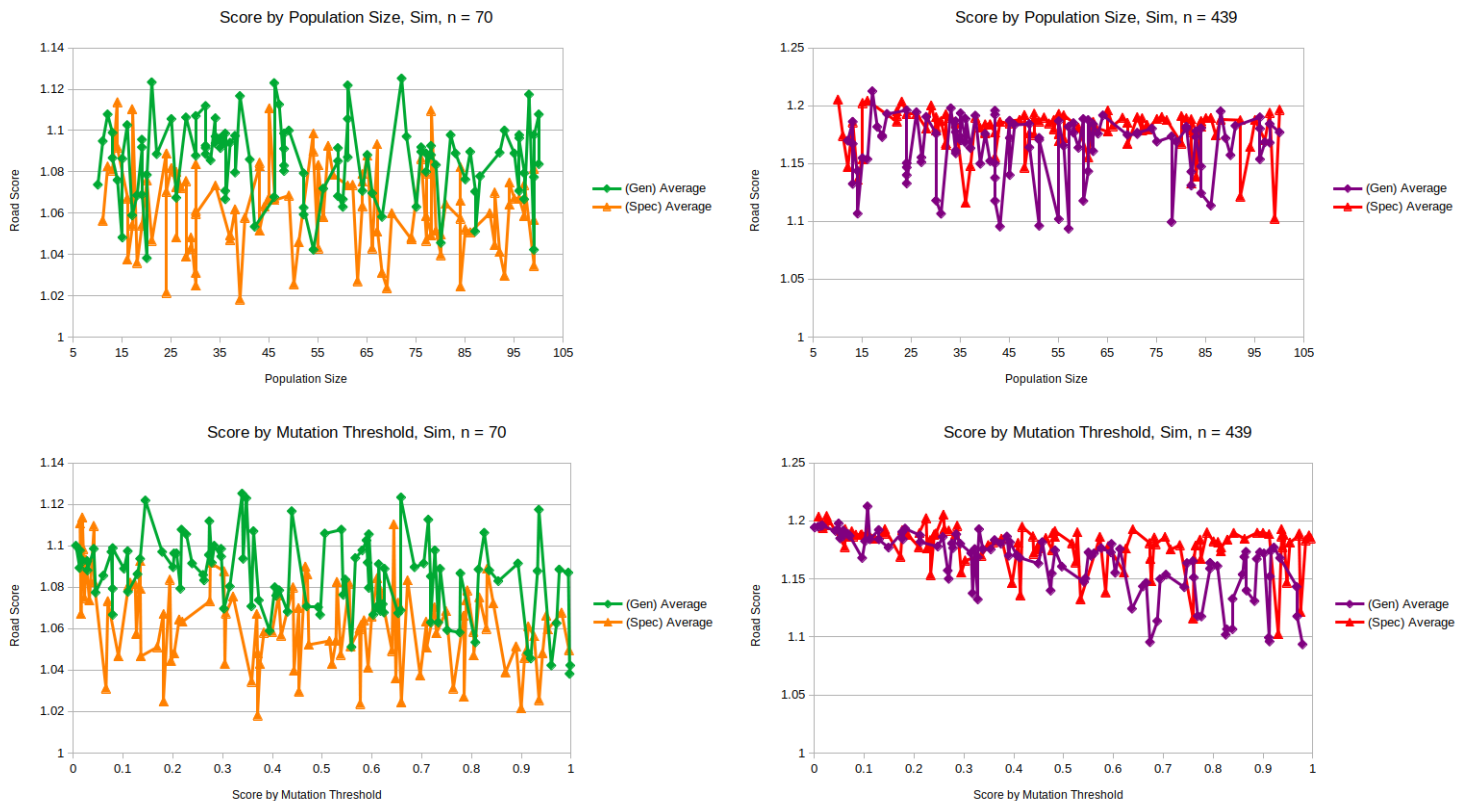
Z powyższych wykresów spróbujmy teraz wyciągnąć kilka wniosków:





- Jak widać dla wariantu symetrycznego, dla rozmiaru wielkości 70 o wiele lepiej zadziałał zestaw trybów deykowany do tych instancji, jednakże dla rozmiaru 439, o wiele lepiej zachował się zestaw ogólny. Przez sformułowanie 'lepiej' rozumiemy tutaj wartości częściej osiągnane bliższej wartości rozwiązania najlepszego.
- Dla wariantu symetrycznego widać również, że dla każdej instancji zestaw danych ogólny wykonywał mniej iteracji (koncentracja w 'dolnej' części wykresu). Może być to powodowane tym, że jest on uwarunkowany po części parametrem *crossCount*, który to mówi o liczbie wykonywanych krzyżowań - widzimy tutaj zatem 'średnią' zależność tego parametru od wykonanej liczby iteracji.
- Ogólny wniosek mamy zatem taki (i powtórzymy go zapewne przy okazji dalszej analizy): dla naszej implementacji różne zestawy trybów będą się inaczej zachowywały dla każdej instancji, zatem najlepszą metodą byłby dobór wszystkich trybów i parametrów do każdej instancji z osobna.
- Dopowiedzmy jeszcze tylko, że dla wariantu asymetrycznego o dziwo oba warianty były dosyć zbalansowane pod względem wydajności, co zresztą widać na rozrzucie danych

### 3.2.2 Wykresy wobec parametrów dla każdej instancji





W tej części pokażemy wykresy w rozbiu o każdy parametr z osobna (traktujemy teraz wszystkie 100 przeszukiwań jako 1 zbiór i dzielimy go względem danego parametru). Pominiemy jednak wykresy dla parametru *crossCount*, ponieważ dla zestawów specyficznych dla danego typu (a/symetryczne) nie bierze on udziału):





#### Symetryczne





## Asymetryczne





Z powyższych wykresów spróbujmy wyciągnąć kilka wniosków:

- Powtórzmy tutaj na początek wniosek z poprzedniej części, a konkretnie, że mimo wszystko zestawy trybów znacznie różnią się od siebie wydajnością (i wpływem na ogólny wynik hiperparametrów) w zależności od wybranej instancji.
- Wydawać by się mogło, że najmniejszy wpływ na wyniki ma wielkość populacji początkowej (na wszystkich wykresach wyniki są dosyć 'zbalansowane' niezależnie od tej wartości)
- Dla instancji mniejszego rozmiaru widzimy ogólnie mniejszą zależność od hiperparametrów, chociaż dla obu wariantów możemy zauważyć, że optimum dla intensyfikacji jest w okolicach *magicznej* 7, natomiast dla crossSize w okolicach 9.
- Dla instancji większego rozmiaru możemy zauważyć, że zwiększanie prawdopodobieństwa mutacji znacznie poprawia jakość rozwiązania, jednakże zwiększanie intensyfikacji ją pogarsza. Można zatem powiedzieć, że najlepiej jest 'często mutować, ale delikatnie'. Natomiast wielkość parametru crossSize waha się w okolicy 12.

### 3.2.3 5 najlepszych

Teraz spójrzmy na ranking 5 najlepszych zestawów parametrów dla każdej z badanych instancji:

Tabela 5.		n = 70				n = 439			
Symetryczne		popSize	mutThresh	mutInt	crossSize	popSize	mutThresh	mutInt	crossSize
Miejsce									
1		39	0.370261	13	19	51	0.912935	1	11
2		69	0.576427	12	7	57	0.979261	2	2
3		84	0.658883	19	8	43	0.673103	1	12
4		24	0.899584	12	13	78	0.911664	1	12
5		50	0.935501	7	5	55	0.825131	1	14

I wyciągnijmy z nich parę wniosków:

- Jak widzimy, dane otrzymane w tabeli nawet pokrywają się po części z tym, co zaobserwowaliśmy na wykresach, a konkretnie, a zwłaszcza to widać dla instancji 'dużych' i parametrów związanych z mutacją (często, acz lekko).
- Dla instancji 'mniejszych' (przypomnijmy że zauważyliśmy na wykresach, że wyniki wydają się bardziej zbalansowane) dane w tabeli bardziej się różnią od siebie (większy rozrzut pomimo wzięcia tylko pierwszej 5), i powiedzmy, że ranking wydaje się nieco bardziej 'losowy' - ale dalej nam determinuje 'zwycięzcę'

Tabela 6.		n = 71				n = 443			
Asymetryczne	Miejsce	popSize	mutThresh	mutInt	crosSize	popSize	mutThresh	mutInt	crosSize
	1	91	0.0661295	18	17	91	0.993212	19	12
	2	15	0.0222585	14	4	78	0.00685312	17	3
	3	92	0.0293365	20	8	91	0.989566	16	5
	4	47	0.0490319	10	17	80	0.0753719	10	4
	5	59	0.383063	5	7	93	0.1842	10	3

### 3.2.4 Ostatecznie wybrane najlepsze

Tak jak wcześniej powiedzieliśmy, nie można jednoznacznie wyznaczyć najlepszych hiperparametrów dla całej metody, jednakże możemy wyznaczyć najlepszy zestaw danych dla poszczególnych instancji. Dlatego tak właśnie teraz postąpimy, i w dalszych eksperymentach będziemy używać następujących zestawów:

Tabela 7.	Instancja	Tryby					Hiperparametry			
		Start	Sel.	Mut.	CrossM	CrossT	popSize	mutThresh	mutInt	crosSize
	Sym70	1	0	3	2	2	39	0.370	13	19
	Sym439	1	0	0	1	1	51	0.913	1	11
	Asym71	1	0	0	1	2	91	0.067	18	17
	Asym443	1	0	0	1	2	91	0.993	19	12


## 3.3 Badanie wpływu zastosowania 'lokalnej poprawy'



Przy zastosowaniu wyników z 2 poprzednich eksperymentów postanowiliśmy zbadać wpływ działania mechanizmu 'lokalnej poprawy' na wyniki.

Badaliśmy te same 4 instancje, co w przypadku poszukiwania hiperparametrów, dlatego że jak się nam udało ustalić, najlepiej jest dobrać je do każdej instancji z osobna.

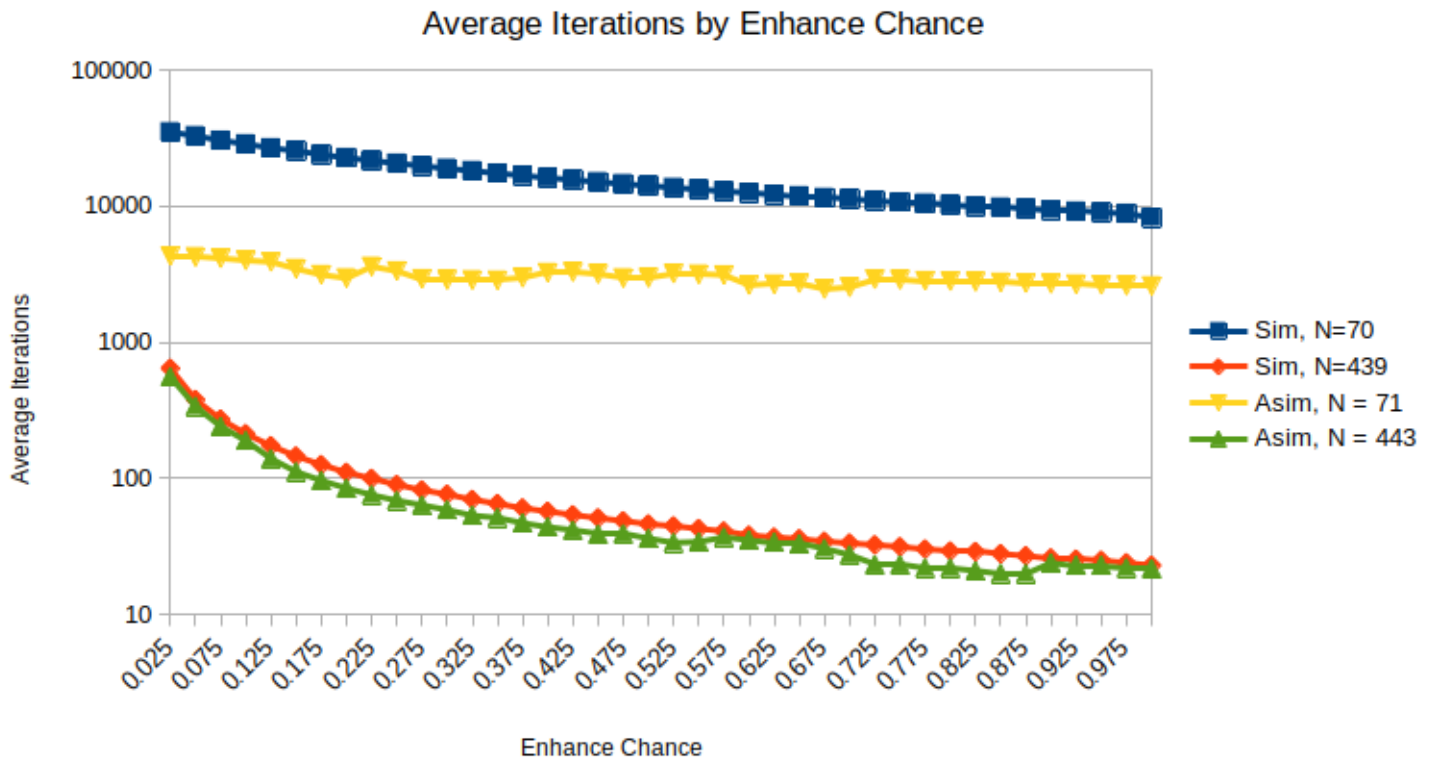
*Lokalna poprawa* - z pewnym prawdopodobieństwem (określanym parametrem *enhanceChance*) po skończonej mutacji (czyli po wszystkich iteracjach) na osobniku wykonujemy algorytm lokalnej poprawy, czyli iteracyjnie przechodzimy przez piątki kolejnych miast i tak modyfikujemy trasę, aby w każdej z tych iteracji przejście było minimalne - zatem najpierw 'poprawiamy' miasta 1-5, potem 2-6 itd. Takich możliwych przejść jest 6 (ponieważ zaczynamy zawsze z 1 i kończymy na 5), zatem jest to w miarę szybkie (dzieje się w czasie liniowym względem liczby miast) i nie powinno znacząco wpływać na liczbę wykonywanych iteracji.

W testach wykonaliśmy 10 powtórzeń dla każdej wartości parametru z zakresu [0.05; 1.0] ze skokiem o 0.05. Wyniki przedstawimy na wykresach (będziemy pokazywali średnią, oraz najlepszy uzyskany wynik):





Zamieścimy jeszcze, jak wygląda wykres średniej liczby wykonanych iteracji względem badanego parametru:







Analiza tutaj jest dosyć prosta i oczywista: Parametr ten nie wpływa zbyt korzystnie na rozwiązanie, a czasem nawet czas poświęcony na jego wykonywanie sprawia, że wykonujemy znacznie mniej iteracji, przez co nie nadążamy z dotarciem do rozwiązań 'względnie dobrych'

### 3.4 Badanie wpływu 'wieku' osobników


Eksperyment analogiczny do poprzedniego (w sensie metodologii, wyboru instancji i parametrów), jednak tym razem badaliśmy wpływ zastosowania wieku na rozwiązanie. Oznaczyliśmy go jako *AgeMax*, przy czym oznacza on, że osobnik będący w populacji dłużej niż *AgeMax* w procesie selekcji jest 'usuwany' z populacji. Zastosowaliśmy tutaj jednak pewną formę elitaryzmu, ponieważ podczas każdej selekcji 'zerujemy' wiek najlepszego osobnika (Najlepszy ma prawo *Picia ze źródła wiecznej młodości*), dzięki czemu go nie tracimy.

W testach wykonaliśmy 10 powtórzeń dla każdej wartości z zakresu [1;20], a wyniki przedstawiamy na wykresach:



Zamieścmy jeszcze, jak wygląda wykres średniej liczby wykonanych iteracji względem badanego parametru:

Iterations by Age Max



A teraz przeanalizujemy otrzymane wyniki:

- Z liczby iteracji widać, że nie wpływa tutaj to znacząco na poziom zaawansowania populacji, zatem można stosować ten parametr 'wstępnie bezstratnie'
- Pomimo nieco losowego rozrzutu, to widzimy zadziwiającą zależność w obrębie jednego rodzaju (a/symetryczne), a konkretnie lokalne minima dla wartości odpowiednio 15 oraz 11
- Stwierdzamy zatem, że mimo wszystko ten parametr warto używać, i będziemy z niego korzystali.

### 3.5 Porównanie najlepszych wyników z algorytmem TabuSearch

Aby jakoś porównać działanie naszego algorytmu, zestawimy go tutaj z zaimplementowanym algorytmem *TabuSearch*, gdzie Tabu będzie miało następujące parametry:

- rozwiązanie startowe - najlepsze z losowych znalezionych w czasie 1 sekundy
- Wielkość listy Tabu -  $\sqrt{n} + 2$
- Liczba iteracji bez poprawy:  $\frac{(|LT|*2+1)*3}{2}$
- Otoczenie rotacyjne (Cykliczne zmiany między otoczeniami *Invert*, *Insert*, *Swap*)
- Kik rotacyjny (jak wyżej)
- Wielkość Kik'a = 7
- Korzystanie z mechanizmu Listy Długoterminowej

Natomiast *Genetic* otrzymane z eksperymentów z poszukiwaniami. Jendakże, aby nie przeprowadzać pponownie poszukiwania najlepszych hiperparametrów dla każdej instancji, przyjęliśmy założenia, że wprowadzimy 1 'uśrednione' dla wszystkich (ale w dalszym ciągu rozróżniamy symetryczne i asymetryczne):

- Symetryczne:
  - startMode = 1
  - selectionMode = 0
  - mutMode = 3
  - crossMode = 2
  - crossType = 2
  - populationSize = 45
  - mutationThreshold = 0.64
  - mutationIntensification = 13
  - crossSize = 19
  - crossCount = 177
  - enhanceChance = 0.01
  - ageMax = 15
- Asymetryczne:
  - startMode = 1
  - selectionMode = 0
  - mutMode = 0
  - crossMode = 1
  - crossType = 2
  - populationSize = 91
  - mutationThreshold = 0.99
  - mutationIntensification = 18
  - crossSize = 12



- crossCount = 176
- enhanceChance = 0.01
- ageMax = 11

Testowaliśmy każdą z 16 badanych instancji, oraz każdemu z algorytmów daliśmy budżet czasu równy 90 sekund (Zatem Tabu działał przez 89). Aby jednak dać jakąś szansę (i odrobinę zredukować losowość) algorytmowi genetycznemu, wykonaliśmy dla niego 3 iteracje po 30 sekund, a następnie wybraliśmy najlepszy. W ten sposób jego wyniki mają szansę być nieco bardziej miarodajne. Wyniki przedstawimy w tabeli:

Tabela 8. Instancje	Wynik Tabu	Najlepszy Gen	Stosunek G:T
Sim, 52	7542	7772	1.03049588968443
Sim, 70	676	696	1.02958579881657
Sim, 76	550	564	1.02545454545455
Sim, 127	118921	125369	1.05422086931661
Sim, 150	26899	28935	1.07569054611696
Sim, 318	172089	47532	0.276205916705891
Sim, 318	202317	47565	0.235101350850398
Sim, 439	1144057	124299	0.108647558644368
Asim, 56	1660	2058	1.23975903614458
Asim, 65	2032	2438	1.1998031496063
Asim, 71	2162	2531	1.17067530064755
Asim, 100	37931	42574	1.12240647491498
Asim, 171	3617	5123	1.41636715510091
Asim, 323	2243	2742	1.22246990637539
Asim, 358	2823	3407	1.20687212185618
Asim, 443	5461	5730	1.04925837758652

- Jak widzimy, dla mniejszych instancji Tabu okazało się znacznie lepsze, co tłumaczymy tutaj po części ulosowaniem metody *Genetic*
- Jednakże mamy 'anomalie' dla większych instancji symetrycznych, w postaci znacznie gorszego wyniku dla Tabu. Tłumaczymy tutaj to jednak tym, że startowało ono z rozwiązań praktycznie losowych, oraz korzystało z listy długoterminowej, zatem zwyczajnie nie zdążyło dotrzeć do rozwiązań porównywalnych do *Genetica*.



### 3.6 Badania nad Modelem Wyspowym


Model wyspowy zaimplementowano w następujący sposób:

- Każda z wysp prowadzi własną instancję algorytmu genetycznego na pojedynczym rdzeniu procesora, wyjściowa populacja losowa, parametry (wybrane najlepsze z uprzednich testów):
  - populationSize = 50
  - mutationIntensification = 13
  - crossSize = 1
  - crossCount = 177
  - crossMode = 1
  - mutMode = 0
  - crossType = 1
  - selectionMode = 0
  - mutationThreshold = 0.6
  - time = 30.0
- po ustalonej liczbie iteracji, z każdej z wysp zabierano  $k$  osobników, po czym z powstałej puli w losowy sposób wysyłano ich z powrotem na wyspy

Badania przeprowadzono na instancji st70.tsp, każda kombinacja parametrów została uruchomiona trzykrotnie, a wynik został uśredniony.

## Wpływ długości interwału pomiędzy mieszaniem





## Wpływ liczby osobników podlegających mieszanii



Na każdym z wykresów mniej lub bardziej, ale zawsze widać tendencję spadkową, co pozwala zakładać, że model wyspowy został zaimplementowany prawidłowo. Ulepszenie nie jest liniowe, ale skuteczne. Najszybszy zysk widać przy długich interwałach pomiędzy mieszaniem, w przypadku `Interval=1000` wartość funkcji celu już przy dwóch wyspach była znacznie lepsza od pojedynczej, potem jednak zyski kolejnych wysp były mniejsze. Dla parametru liczby osobników branych do mieszania nie widać szczególnie jakiś własności, poza nieprzewidywalnością wyniku, kiedy bierzemy tylko po jednym z osobników.

## 4 Tabele Dodatkowe

Tabela D1. Wspólne Id	StartMode	SelectionMode	MutMode	CrossMode	CrossType	Sum	Avg
76	1	0	0	1	1	810.8125	50.67578125
75	1	0	0	1	0	791.4375	49.46484375
77	1	0	0	1	2	784.875	49.0546875
115	1	1	0	2	1	876.875	54.8046875
113	1	1	0	1	2	885.625	55.3515625
112	1	1	0	1	1	923.5	57.71875
114	1	1	0	2	0	931.125	58.1953125
103	1	0	3	1	1	1129.1875	70.57421875
116	1	1	0	2	2	1051.875	65.7421875
111	1	1	0	1	0	1049.25	65.578125
80	1	0	0	2	2	945.8125	59.11328125
139	1	1	3	1	1	1139.875	71.2421875
107	1	0	3	2	2	1210.125	75.6328125
106	1	0	3	2	1	1291.25	80.703125
142	1	1	3	2	1	1279.4375	79.96484375
79	1	0	0	2	1	1093.1875	68.32421875
143	1	1	3	2	2	1387.3125	86.70703125
138	1	1	3	1	0	1344.8125	84.05078125
141	1	1	3	2	0	1335.875	83.4921875
149	2	0	0	1	2	1129.125	70.5703125
104	1	0	3	1	2	1377.6875	86.10546875
78	1	0	0	2	0	1200.875	75.0546875
102	1	0	3	1	0	1441.9375	90.12109375
140	1	1	3	1	2	1511.75	94.484375
186	2	1	0	2	0	1361.6875	85.10546875
210	2	1	3	1	0	1498.25	93.640625
105	1	0	3	2	0	1359	84.9375
152	2	0	0	2	2	1386	86.625
148	2	0	0	1	1	1344	84
187	2	1	0	2	1	1421	88.8125
184	2	1	0	1	1	1365.125	85.3203125
185	2	1	0	1	2	1404.5625	87.78515625
178	2	0	3	2	1	1666.8125	104.17578125
151	2	0	0	2	1	1436.0625	89.75390625
150	2	0	0	2	0	1555.5625	97.22265625
89	1	0	1	2	2	1605.0625	100.31640625
213	2	1	3	2	0	1673.5	104.59375
179	2	0	3	2	2	1722.5625	107.66015625
183	2	1	0	1	0	1596.75	99.796875
188	2	1	0	2	2	1606.75	100.421875
88	1	0	1	2	1	1695.8125	105.98828125
211	2	1	3	1	1	1879.125	117.4453125
147	2	0	0	1	0	1718.4375	107.40234375
81	1	0	1	0	0	1623.125	101.4453125
175	2	0	3	1	1	1874.625	117.1640625
125	1	1	1	2	2	1875.3125	117.20703125
214	2	1	3	2	1	2064.4375	129.02734375
72	1	0	0	0	0	1665.1875	104.07421875
212	2	1	3	1	2	1916.25	119.765625
123	1	1	1	2	0	1920.1875	120.01171875

Tabela D2 (2 Pisemnie)							
Id	StartMode	SelectionMode	MutMode	CrossMode	CrossType	Sum	Avg
107	Hybryda	Turniej	Losowa	Part.Map.	Size/2	98	12.25
102	Hybryda	Turniej	Losowa	Mod.Ord.B.	All Par	124	15.5
106	Hybryda	Turniej	Losowa	Part.Map.	Size/2	127	15.875
103	Hybryda	Turniej	Losowa	Mod.Ord.B.	Pop=20	141	17.625
142	Hybryda	Ruletka	Losowa	Part.Map.	Pop=20	161	20.125
139	Hybryda	Ruletka	Losowa	Mod.Ord.B.	Pop=20	163	20.375
140	Hybryda	Ruletka	Losowa	Mod.Ord.B.	Size/2	188	23.5
143	Hybryda	Ruletka	Losowa	Part.Map.	Size/2	197	24.625
138	Hybryda	Ruletka	Losowa	Mod.Ord.B.	All Par	202	25.25
104	Hybryda	Turniej	Losowa	Mod.Ord.B.	Size/2	206	25.75